

毕设题目： 具身智能无本体采集系统视触融合模仿学习方法研究

无 28 陈帅文 2022010701

一. 研究背景与意义:

近年来，具身智能受到广泛关注。它已被纳入国家“十五五”规划建议^[1]，成为需要着力打造的新经济增长点，在工业制造、家庭服务、医疗康复、仓储物流等领域拥有巨大的潜在市场。

传统人工智能强调“认知智能”，如图像识别、语音识别和自然语言处理。而具身智能还需要具备与环境交互并施加影响的能力。两者关注点有所不同，但方法论是相通的：数据驱动的发展模式。这一点在大语言模型的发展中表现尤其明显，2023 年，LLaMA 1 使用 1T 数据进行训练^[2]，2024 年底，DeepSeek-V3 报告披露其预训练约 14.8T tokens^[3]，Qwen2.5 预训练数据达到 18T^[4]，随着数据量不断增长，语言模型的认知能力也不断增强。

除了数据规模外，数据的模态也同样重要。具身智能需要真正与世界交互，就必须拥有多模态的信息输入。例如，机器人在执行“拿起瓶子并拧开瓶盖”时，需要多种模态信息的协同：视觉信息确定瓶子和瓶盖的位置，语言指令信息了解需要完成的任务，通过本体感觉定位手臂与手的位置，通过触觉反馈判断是否握稳瓶子以及感知拧瓶盖时阻力大小。想要实现与环境可靠交互的具身智能，离不开视觉、语言、触觉、本体感知等多模态信息的融合。

在具身领域，目前各种项目和数据集已经证明：数据量增加，数据模态扩展，具身模型能力越强。Google Robotics 团队提出的 RT-1 模型使用 130k 机器人轨迹进行训练^[5]，随后推出的 RT-2 加入 1B 互联网图文数据^[6]，将互联网知识迁移到机器人控制中，实现对新物体，新技能的零样本泛化。Open X-Embodiment 项目构建了包含上百万段机器人交互的开放数据集^[7]，AgiBot-World 同样收集了大规模多任务操作数据用于训练^[8]。近期，RDT2^[9]，Gen0^[10]等项目使用大量无本体数据进行训练，最终模型能完成长流程精细操作。因此，我们可以说，具身智能的竞争，是大规模、多模态数据获取和利用的竞争。

然而，要想获取如此海量且多样的具身交互数据，并非易事。传统的方法是利用远程操作(teleoperation)由人来操作机器人完成任务，采集数据。但直接依赖机器人本体进行远程操作的数据采集存在明显局限：(1) 主从机械臂遥操作需要人为控制与任务机器人构型相同的机械臂完成演示，硬件成本高且场景受限，采集过程严重依赖于机器人本体，而且操作者看到的人机视角不一致；(2) 基于 VR 设备的遥操作通过 VR 捕捉人体动作映射到机器人，但缺乏直接力反馈，操作时的延迟和定位误差会降低任务成功率。总之，依赖机器人本体的遥操作采集难以

大规模展开。在此背景下，如何脱离机器人本体限制、高效获取多模态演示数据成为研究热点。一些工作提出了“无本体”的数据采集方案，即不直接依赖真实机器人硬件，由人佩戴或操作专门装置来完成示范动作并记录数据，从而大大提高数据增长速度。

除了数据规模，数据的模态丰富性也是关键因素。当前研究者开始关注将触觉等物理交互信息纳入机器人学习框架，以弥补仅依赖视觉可能存在的不足。一些融合视觉与力/触觉的无本体采集方案为模仿学习引入了触觉信息。然而，目前的此类方案仍不完善：一方面，它们大都缺少演示者第一视角的视觉信息，导致采集到的视觉场景范围有限，难以涵盖复杂任务中的全局环境信息；另一方面，由于硬件和同步方面的限制，这些尝试往往只能获取有限模态种类的数据，难以支持语言、视觉、触觉等多模态信息的同步融合。这使得现有方法在处理涉及长时间、多步骤的复杂任务时表现不理想。

本项目旨在探索包含视觉、触觉数据的无本体采集系统，为具身数据采集提供一种可扩展路径；尝试弥合人类演示与机器人执行之间的域间差异 (domain gap)，从而使模型能够更有效地从人演示中学习并泛化到机器人；融合视觉、触觉、语言等模态信息进行决策建模，以提升机器人对复杂接触操作和长序列任务的处理能力。从而提高机器人从无本体数据中学习的效率和鲁棒性，推动更大规模的具身智能模型训练，加速机器人技术在实际场景中的落地应用。

二. 文献综述:

(一) 数据采集方法研究

针对真实世界数据采集，研究者提出了多种方案，主要可分为遥操作采集和无本体采集两大类。在遥操作采集方面，传统方法包括主从机械臂遥控和虚拟现实 (VR) 遥控两种形式。前者要求操作者使用与目标机器人相同结构的主控机械臂进行操作，机器人作为从动机械臂，复制人的动作完成任务。这种方式能够获得高保真的示范轨迹，但需要两套机器人系统，并且演示环境局限在机器人工作空间内。此外，由于人操作时观看的是外部摄像头视角或者人眼视角，人与机器人的观测视角存在差异，这可能导致采集到的数据实际不可用。代表工作如 ALOHA，使用一套主从方案实现了厨房操作任务^[11]；GELLO 则使用一套低成本框架实现了多种机械臂的接入和数据采集^[12]。这种思路也被很多商业公司使用，如自变量公司的量子一号机器人使用主从臂方式进行采集。VR 遥操作则通过在操作者身上安装定位设备 (如 VR 控制器) 捕捉人体动作 (尤其是操作末端位置)，并实时映射到机器人关节运动上。Open TeleVision 系统便是此类方法的典型代表，它利用沉浸式 VR 界面让操作者以第一人称视角控制机器人^[13]。智元机器人也使用类似方案进行数据采集，得到了 Agibot-world 这一大型数据集。VR 方法降低

了对物理双臂设备的需求，但由于缺乏真实力反馈、存在网络延迟和定位误差等因素，其操控精度和成功率会受到影响。总体而言，遥操作采集依赖于机器人本体，受限于设备成本和物理性能，难以满足上万小时数据采集的扩展需求。

面对上述局限，学术界和工业界开始探索“无本体”的数据采集途径，以实现在无真实机器人参与的情况下获取机器人演示数据。这类方法由人类演示者在真实环境中完成任务并采集数据，随后直接将这些演示数据用于模型训练。RSS 的一项研究提出了通用接口 UMI，提供了首个无本体示教方案^[14]。UMI 为了弥补人手和机械臂末端的差距，采用了一个手持的机械末端供人握持操作，使用腕部的鱼眼相机获得视觉信息，采用两个侧向镜面为单目视觉提供深度线索，另配有惯性测量单元（IMU）追踪手部运动轨迹。此外，DexCap 利用动作捕捉手套记录操作者手指细节动作，同时通过腕部相机和 IMU 获取手臂的运动轨迹，它增加了一枚胸前佩戴的广角相机，辅助捕获更稳定、完整的环境视角^[15]。与 UMI 相比，DexCap 在采集人手细节和减小摄像抖动方面有所增强，适合记录灵巧手的操作过程。最近，一些研究进一步改进了无本体采集的速度和通用性。例如，Fast-UMI 系统对 UMI 的硬件和算法进行优化，大幅提高了数据采集设备的可靠性^[16]。

在工业界，利用大众力量众包采集机器人演示数据的探索也取得了成果。Generalist AI 使用指套类型采集设备，使用者只需佩戴指套状的传感设备并按照提示完成诸如抓取、搬动物品等任务，系统便会自动记录下手部运动和交互过程的数据。据报道，该方案峰值时每周可获取超过一万小时的人类演示数据。Generalist AI 团队借助这套众包系统积累了前所未有的大规模机器人交互数据，并据此训练了通用机器人模型 GEN-0，在长序列复杂任务中展现出显著优于以往方法的性能。这一成果证明，通过互联网众包与可穿戴装置的结合，可以突破过去数据匮乏的瓶颈，为具身智能的研究与应用开辟新的道路。Sunday Robotics 也使用类似方案，专注于家庭服务机器人领域^[17]。

（二）多模态无本体数据采集

在机器人操作任务中，单纯的视觉信息有时不足以全面反映环境状态，尤其在涉及物体接触的操作中，力觉和触觉提供了关键线索。因此，为提高演示数据对接触细节的刻画，研究人员开始尝试将力/触觉传感器整合到数据采集系统中。一种思路是在演示过程中记录力传感器的数据。例如，ForceMimic 系统通过在手持末端上安装六轴力/力矩传感器，同步捕获人在执行推、拉、插入等接触动作时施加的力^[18]。这些力信号与视觉轨迹一同用于训练策略，使机器人能更好地复现人类的用力方式，从而完成丰富的接触操作。另一类思路是直接采集触觉传感信息，exUMI 在末端执行器上集成触觉传感器以感知手爪与物体间的接触状态^[19]。

他们将连续的触觉表示建模为一个时序预测问题,通过这种方式,在模型训练时融合同步采集的触觉-视觉序列,从而能够感知细微的接触变化。上述研究初步展示了将触觉融入无本体采集的可能性。然而,这些方案当前仍存在局限:(1) 缺少演示者第一人称的视觉数据。ForceMimic 和 exUMI 主要利用安装在手部或工具上的腕部摄像头获取局部视角,未采集演示者第一视角的全局视觉信息。在复杂场景中,缺乏全局视角可能导致模型对环境理解不完整,影响长程规划;(2) 长时间、多步骤任务支持不足。由于设备携带不便以及数据同步困难,当前融合触觉的采集多针对短时间的单一操作环节,对于涉及多个子任务的长序列操作,缺乏相应的示范和学习框架。因此,在演示数据模态拓展方面,如何既获取宏观视角下的环境信息,又捕捉微观层面的接触细节,并保证多模态数据在时间同步与空间对齐方面精确一致,仍有很大的提升空间。

(三) 多模态模仿学习与策略建模

近年来,为了充分利用多模态感知信息提升机器人的智能化水平,研究人员提出了许多将视觉、语言等模态引入策略建模的工作。其中,备受关注的是视觉-语言-动作模型 (Vision-Language-Action, VLA) 。这类模型通常利用预训练的视觉-语言模型理解高层语义,再结合机器人控制模块输出动作,从而将互联网的丰富知识引入机器人决策。例如,Google 的 RT-2 是早期的 VLA 模型之一,它将一个经过海量图像-文本训练的视觉语言模型接入机器人控制环路,使机器人能够借助视觉语义信息完成指令驱动的操作。然而,RT-2 及类似的 VLA 模型主要关注视觉和语言,对触觉等物理交互信息尚未涉足。

面对这一局限,研究人员提出了 Tactile-VLA 框架,将触觉信号整合到 VLA 模型中^[20]。具体而言,他们设计了一个包含视觉、语言和触觉三个输入分支的 Transformer 模型,其中触觉分支接收传感触觉流,并在模型的中间表示中与视觉、语言信息融合。实验表明,引入触觉后的模型在需要触觉判断的操作任务上泛化性能有明显提升。另一项相关工作提出了 RDP (Reactive Diffusion Policy) 方法^[21]。RDP 采用了“慢-快”双策略架构:慢策略由视觉主导,先产生大致规划;快策略以触觉反馈为依据,对接触过程中的细节动作进行快速调整。该方法使用三维形变场来表征触觉信息,将触觉嵌入扩散模型的动作生成过程中。结果证明,与单纯视觉策略相比,结合触觉反馈的 RDP 在削皮等需要精细用力控制的任務上成功率更高。值得注意的是,上述方法的数据多来自人工遥操作的小规模实验室数据集,触觉模态的数据量相对有限。如何在大规模数据情境下有效融合触觉,仍需要进一步探索。

(四) 无本体模仿学习中的域差异与增强技术

无本体演示数据用于机器人学习时，一个重要挑战是人类与机器人的域差异 (domain gap)。这种差异主要体现在两个方面。一是视觉视角的差异：不同人演示时第一视角的位置和朝向各异，取景范围、高度、角度不尽相同；即使是同一个人，在演示过程中头部也会随动作而移动。而机器人通常使用固定安装在机身上的摄像头，其视角范围和变化幅度远不及人类灵活。这导致模型从人演示学到的策略迁移到机器人上时，视觉输入的分布发生改变，性能可能下降。二是操作主体的差异：人类的手臂和手部在外形和材质上与机器人的机械臂和夹爪存在显著差异，这些外观和动力学上的差异会导致模型难以直接将人在人手演示中学到的动作策略复现到机器人上。因此，域差异被认为是目前限制无本体模仿学习性能的核心瓶颈之一。

为缩小这一差距，研究者提出了一系列数据增强与域适配的方法。其中，大部分工作聚焦于操作者形态的差异，即如何消除人手在视觉中的干扰，或将人动作映射为机器人动作。例如，MV-UMI 方法利用计算机视觉技术来消除演示画面中与人类操作者相关的元素。具体来说，MV-UMI 通过对多角度摄像画面进行语义分割，将图像中出现的人手、手臂等任务无关的像素区域遮盖并移除，然后使用图像修复算法填补被遮盖的区域，从而生成没有人手干扰的纯净示教图像^[22]。这在很大程度上缓解了视觉上的形态差异，使机器人在学习时不会把人类肢体当作环境的一部分。然而，目前针对视角差异的数据增强方法几乎仍是空白。一些视觉算法的进步为视角归一化提供了新的思路。例如，Visual Geometry Grounded Transformer (VGGT) 模型能够从单张或少量图像直接推断场景的主要三维属性^[23]；OmniVGGT 在 VGGT 的基础上进一步扩展，使其能够接受视觉、语言等多模态输入，从而实现更全面的场景理解^[24]。这些视觉模型表明，通过深度学习有可能有效恢复演示环境的几何信息。未来或可将类似 VGGT 的三维感知技术应用于示教数据的视角变换：先重建环境的三维模型，再渲染出固定机器人视角下的图像序列，从根本上消除人机视角差异。

综上所述，已有文献为本课题提供了重要参考：数据采集方面，无本体采集设备和众包模式有助于大幅扩充机器人训练数据，但当前的设备尚需在多模态集成和数据同步上加强；多模态融合方面，触觉信息的重要性日益凸显，一些工作已证明其价值，但仍缺乏针对规模化数据的解决方案；域差异问题开始受到重视，特别是在去除人手干扰上取得进展，但在视角统一性上仍存在空白；策略学习方面，多模态大模型和生成式策略学习显示出巨大潜力。本文将在上述研究基础上，针对其中的薄弱环节提出新的方法，具体的研究问题和方案将在下文阐述。

三. 研究问题与目标

综合以上背景与文献分析，本课题将围绕以下三个科学问题展开研究：

(1) 大规模多模态采集需求与现有硬件系统能力之间的差距。当前的演示数据采集设备在可扩展性和模态丰富性上存在局限性，难以获取同时包含视觉（特别是头部视角）、触觉等多模态信息。本课题旨在设计一套高效的无本体数据采集系统，以突破现有硬件对数据规模和模态的限制。

(2) 模仿学习中，人类采集员与机器人本体的差异。人类采集员在演示中使用的视角、操作手段与机器人存在显著差异，这种“域差异”（domain gap）会导致直接模仿学习效果不佳。本课题需要研究有效的视角归一化和数据增强方法，减少不同演示主体在观察视角上的差异。同时，弥合人手与机器人机械手在外观形态上的视觉差异，从而提升模型的泛化能力。

(3) 多模态信息融合的策略学习问题。在具身智能决策中，如何将视觉、语言、触觉等多模态信息有效融合用于策略建模和动作决策是一项巨大的挑战。本研究需要探索新的模型架构或学习方法，将触觉反馈融入现有视觉-语言模型体系中，期望所构建的模型能够从多模态演示中学习复杂的操作策略，尤其在涉及精细力控的任务上，展现更高的成功率和鲁棒性。

围绕上述科学问题，本课题的总体研究目标可概括如下：

(1) 形成一套能够采集多模态信息（包括头部第一视角视觉和触觉数据）的无本体采集设备，实现各传感通道的数据同步和空间标定，为大规模数据获取提供支持。

(2) 提出一种针对人-机视角差异的数据处理流程，能够将不同采集员采集的图像归一化到机器人固定视角下，并通过生成新视角样本等数据增强手段，降低模仿学习过程中的域差异影响。

(3) 构建一个融合视觉、语言和触觉信息的模型，使机器人能够从多模态演示中学习复杂的操作策略，尤其在涉及精细力控的任务上表现出更高的成功率和鲁棒性。

四. 研究内容、框架与方法

针对上述研究目标，如图 1 所示，本文将重点开展以下三个方面的研究工作，并由此形成本课题的总体技术路线和框架：




图 1: 研究内容与方法

内容一：数据采集设备构建。本工作首先设计并实现一套支持视觉-触觉信息同步采集的无本体采集设备。为了保证视觉、触觉等多传感器数据的时间同步和空间标定，我们将设计统一的数据同步与标定方案，实现多模态数据在时间轴上的精确同步和空间对齐。预期该设备可用于大规模采集包含第一视角视频、触觉信号等在内的多模态演示数据，为后续模仿学习提供丰富的训练素材。

内容二：数据后处理与增强。针对不同演示者视角不一致导致的数据域差异问题，本工作将提出一套视角归一化处理流程。首先，我们将基于采集到的环境图像，利用计算机视觉方法重建演示场景的三维模型。引入如 VGGT 等学习型模型，直接预测场景的深度图和关键三维结构。借助获得的场景几何，我们可以将原始演示影像转换到机器人视角：根据预设的机器人摄像头参数和位置，在重建的场景模型上渲染出仿真的机器人相机视角画面，并生成对应序列帧。通过上述处理，期望能将不同人演示的数据统一到与机器人观察相一致的分布，从而在训练阶段减少因视角差异导致的性能损失。在这一模块的验证部分，我们将对比未经过视角归一化处理的数据与处理后的数据在相同模型下训练效果的差异，以评估该方法的有效性。

内容三：视觉-语言-触觉多模态联合建模与训练。在具备了多模态演示数据及其视角归一化增强方案后，我们将着手构建融合多模态信息的机器人策略模型。模型总体采用两级架构：一是一个视觉-语言理解模块，用于从环境感知和指令中提取高层语义信息；二是一个动作决策模块，根据前端输出的语义表示以及触觉反馈，生成具体的操作动作序列。最终，我们将在实际机器人平台上部署并验证所训练的策略模型，选取典型的接触操作任务（例如插入与装配、精细抓取等）进行实验，对比有无触觉融合、是否进行视角归一化等条件下机器人的任务成功率和操作表现差异，验证本课题提出方法的有效性。

-
- [1] 中共中央. 中共中央关于制定国民经济和社会发展第十五个五年规划的建议[EB/OL]. 新华网, 2025-10-28[2026-02-22].
<https://www3.xinhuanet.com/politics/20251028/08920d9f557c432e99459f8f468504db/c.html>.
- [2] Touvron, H., Lavril, T., Izacard, G., Martinet, X., Lachaux, M.-A., Lacroix, T., Rozière, B., Goyal, N., Hambro, E., Azhar, F., Rodriguez, A., Joulin, A., Grave, E., & Lample, G. (2023). LLaMA: Open and Efficient Foundation Language Models. arXiv. <https://arxiv.org/abs/2302.13971>
- [3] DeepSeek-AI. (2024). DeepSeek-V3 Technical Report. arXiv. <https://arxiv.org/html/2412.19437v1>
- [4] Qwen Team. (2024). Qwen2.5 Technical Report. arXiv. <https://arxiv.org/abs/2412.15115>
- [5] Brohan, A., Brown, N., Carbajal, J., Chebotar, Y., Dabis, J., Finn, C., ... Zitkovich, B. (2023). RT-1: Robotics Transformer for Real-World Control at Scale. Robotics: Science and Systems (RSS XIX)
- [6] Zitkovich, B., Brohan, A., Brown, N., Carbajal, J., Chebotar, Y., ... Vanhoucke, V. (2023). RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control. In Proceedings of The 7th Conference on Robot Learning (CoRL 2023) (Proceedings of Machine Learning Research, Vol. 229, pp. 2165 – 2183).
- [7] Open X-Embodiment Collaboration. (2024). Open X-Embodiment: Robotic Learning Datasets and RT-X Models. In Proceedings of the IEEE International Conference on Robotics and Automation (ICRA 2024).
- [8] AgiBot-World-Contributors. (2025). AgiBot World Colosseo: A Large-scale Manipulation Platform for Scalable and Intelligent Embodied Systems
- [9] RDT-2: Enabling zero-shot cross-embodiment generalization by scaling up UMI data. <https://rdt-robotics.github.io/rdt2/>
- [10] Generalist AI Team(2025). GEN-0 / Embodied Foundation Models That Scale with Physical Interaction
- [11] Zhao, T. Z., Kumar, V., Levine, S., & Finn, C. (2023). Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware. arXiv. <https://arxiv.org/abs/2304.13705>
- [12] GELLO: A general, low-cost, and intuitive teleoperation framework for robot manipulators. In Proceedings of the Conference on Robot Learning (CoRL 2023) Workshops.
- [13] Cheng, X., Li, J., Yang, S., Yang, G., & Wang, X. (2024). Open-TeleVision: Teleoperation with immersive active visual feedback. In Proceedings of the 8th Conference on Robot Learning (CoRL 2024).
- [14] Chi, C., Xu, Z., Pan, C., Cousineau, E., Burchfiel, B., Feng, S., Tedrake, R., & Song, S. (2024). Universal Manipulation Interface: In-The-Wild Robot Teaching Without In-The-Wild Robots. Robotics: Science and Systems (RSS XX)
- [15] Wang, C., Shi, H., Wang, W., Zhang, R., Fei-Fei, L., & Liu, C. K. (2024). DexCap: Scalable and Portable Mocap Data Collection System for Dexterous Manipulation. RSS 2024 Workshop on Dexterous Manipulation (DM 2024).
- [16] ZhaXiZhuoMa, C., Shi, H., Wang, W., Zhang, R., Fei-Fei, L., & Liu, C. K. (2024). Fast-UMI: A scalable and hardware-independent universal manipulation interface. In Proceedings of the Conference on Robot Learning (CoRL 2024), Proceedings of Machine Learning Research.
- [17] Sunday Robotics Team. (2025). Sunday Robotics: <https://www.sunday.ai/>
- [18] Liu, W., Wang, J., Wang, Y., Wang, W., & Lu, C. (2025). ForceMimic: Force-centric imitation learning for contact-rich manipulation. In Proceedings of the IEEE International Conference on Robotics and Automation (ICRA 2025).
- [19] Xu, Y., Wei, L., An, P., Zhang, Q., & Li, Y.-L. (2025). exUMI: Extensible robot teaching

system with action-aware task-agnostic tactile representation. In Proceedings of the 9th Conference on Robot Learning (CoRL 2025).

^[20] Huang, J., Wang, S., Lin, F., Hu, Y., Wen, C., & Gao, Y. (2025). Tactile-VLA: Unlocking vision-language-action models’ physical knowledge for tactile generalization. arXiv preprint arXiv:2507.09160.

^[21] Xue, H., Ren, J., Chen, W., Zhang, G., Fang, Y., Gu, G., Xu, H., & Lu, C. (2025). Reactive diffusion policy: Slow – fast visual-tactile policy learning for contact-rich manipulation. Robotics: Science and Systems (RSS XXI)

^[22] Xu, Z., Chi, C., Feng, S., Cousineau, E., & Song, S. (2025). MV-UMI: Multi-view universal manipulation interface for in-the-wild robot teaching. arXiv preprint arXiv:2509.18757.

^[23] Wang, J., Chen, M., Karaev, N., Vedaldi, A., Rupprecht, C., & Novotny, D. (2025). VGGT: Visual geometry grounded transformer. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR 2025).

^[24] Peng, H., Li, H., Dai, Y., Lan, Y., Luo, Y., Qi, T., Zhang, Z., Zhan, Y., Zhang, J., Xu, W., & Liu, Z. (2025). OmniVGGT: Omni-modality driven visual geometry grounded transformer. arXiv preprint arXiv:2511.10560.